

PONTIFÍCIA UNIVERSIDADE CATÓLICA DE MINAS GERAIS
NÚCLEO DE EDUCAÇÃO A DISTÂNCIA
Pós-graduação *Lato Sensu* em Inteligência Artificial e Aprendizado de Máquina

Emilly Magalhães do Vale

**UTILIZANDO VISUALIZAÇÃO DE DADOS PARA ANALISAR IMPACTO DA
COVID-19 NO ESTADO DO AMAZONAS**

Manaus
Maio de 2023

Emilly Magalhães do Vale

**UTILIZANDO VISUALIZAÇÃO DE DADOS PARA ANALISAR IMPACTO DA CO-
VID-19 NO ESTADO DO AMAZONAS**

Trabalho de Conclusão de Curso apresentado
ao Curso de Especialização em Inteligência Ar-
tificial e Aprendizado de Máquina, como requi-
sito parcial à obtenção do título de *Especialista*.

Manaus
Maio de 2023

SUMÁRIO

1. Introdução	4
1.1. Contextualização	4
1.2. O problema proposto.....	5
2. Coleta de Dados	6
3. Processamento/Tratamento de Dados	7
4. Análise e Exploração dos Dados	9
5. Ferramentas e Modelos para Visualização de Dados	11
6. Apresentação dos Resultados	13
6.1 A realidade da Covid-19 no Brasil.....	13
6.2 Comparando o Amazonas com outros estados.....	15
6.3 Covid-19 para população indígena	18
6.4 Vacinação tardia.....	19
6.5 Falta de cilindros de Oxigênio.....	20
7. Conclusão	20
8. Links.....	21
REFERÊNCIAS.....	23

1. Introdução

1.1. Contextualização

A pandemia da COVID-19, doença causada pelo novo coronavírus (SARS-CoV-2), teve impactos abrangentes no Brasil, afetando de forma significativa a saúde pública, a economia, o sistema de saúde e a sociedade em geral. Entre as consequências estão um elevado número de óbitos, a sobrecarga dos serviços de saúde, o agravamento das desigualdades sociais, o fechamento de escolas e universidades, a interrupção do processo educacional para milhões de estudantes, e um impacto psicológico e emocional de proporção global (Ferrante et al., 2020; Hallal et al., 2020; Rodrigues; Albertoni; Mendonça, 2020).

De acordo com dados da Organização Mundial da Saúde (OMS), o Brasil ocupa a terceira posição entre os países com o maior número de mortes causadas pela COVID-19, ficando atrás apenas dos Estados Unidos e da Índia. É importante ressaltar que esses países possuem populações significativamente maiores em comparação ao Brasil. Enquanto o Brasil possui cerca de 212,6 milhões de habitantes, os Estados Unidos e a Índia possuem, respectivamente, 329,6 milhões e 1,38 bilhão de habitantes.

Cada estado brasileiro enfrentou a pandemia de forma distinta, devido a diferenças socioeconômicas e capacidades de atendimento médico. Portanto, a proporção da população afetada variou devido a diversos fatores, como medidas de mitigação adotadas, infraestrutura de saúde disponível e comportamento da população. Como resultado, alguns estados conseguiram minimizar e controlar os efeitos da pandemia de forma mais rápida (Matta, Gustavo. 2022).

Segundo dados do Ministério da Saúde, o Amazonas a taxa chegou a 39,1 mortes para cada 100 mil habitantes. O número chegou quatro vezes maior que a média nacional, de 9,5. Ceará (23,7), Pará (21,5), Pernambuco (20,1), Rio de Janeiro (19,8), e Amapá (17,9) também estiveram em pior situação. São Paulo é o estado com maior número de casos confirmados, chegando a ter uma taxa de 10,5 mortes para cada 100 mil habitantes.

Manaus foi a primeira capital brasileira fortemente afetada pelo coronavírus, em abril e maio de 2020, quando a cidade enfrentou explosão de casos, superlotação de

hospitais e cemitérios. Durante o pico da segunda onda da pandemia no Brasil, em janeiro de 2021, capital do estado do Amazonas, enfrentou uma grave crise de saúde devido à falta de oxigênio nos hospitais. A alta demanda por oxigênio devido ao grande número de pacientes com COVID-19 em estado grave sobrecarregou o sistema de fornecimento de oxigênio da cidade (Brasil, 2022).

1.2. O problema proposto

Quando se analisa a pandemia de Covid-19 em um contexto nacional, o Estado do Amazonas, situado na Amazônia brasileira, não registrou o maior número de mortes nem o maior número de casos absolutos. No entanto, foi um dos estados mais proporcionalmente impactados pela pandemia.

Apesar de ser o maior estado em extensão territorial do Brasil, sua população tem enfrentado historicamente condições de pobreza e desigualdade social. Um estudo realizado na Região Metropolitana de Manaus revelou uma grande disparidade no acesso aos serviços de saúde. Essa situação é comum para populações que vivem em áreas remotas e terras indígenas, onde a vulnerabilidade social e econômica limita sua mobilidade no território e as torna mais suscetíveis à disseminação grave da COVID-19.

Diante do impacto causado pela pandemia, o objetivo deste trabalho é utilizar técnicas de visualização de dados para compreender o real impacto e os principais fatores que levaram o estado do Amazonas a ser um dos mais afetados no Brasil, chegando a se tornar o epicentro mundial da pandemia.

Neste estudo será analisado dados oficiais da COVID-19 que possui registros estadual, regional e nacional para analisar e comparar o estado do Amazonas em relação a outros estados da mesma região e com população semelhante.

Também será analisado um dataset onde contém informações exclusivas do Amazonas sobre vacinação, principais sintomas apresentados por pessoas da região, dados da população indígena e muitos outros. O período de três anos de pandemia foi examinado para compreender a evolução da doença ao longo do tempo.

2. Coleta de Dados

Os dados utilizados neste trabalho estão disponíveis em duas fontes, ambas de acesso público. A primeira fonte é o Brasil.io, um projeto que tem como objetivo coletar, organizar e disponibilizar dados abertos no Brasil. Esses dados são coletados de fontes oficiais, como órgãos governamentais, e são disponibilizados gratuitamente de forma estruturada e padronizada para análise, pesquisa e desenvolvimento.

A segunda fonte de dados utilizada foi disponibilizada pela Fundação de Vigilância em Saúde do Amazonas (FVS), um órgão governamental de referência estadual que contribui para a proteção à saúde por meio de ações integradas de vigilância epidemiológica, sanitária, ambiental e laboratorial, além do controle de doenças e agravos. A consolidação dos casos notificados no Amazonas é realizada pela FVS-AM a partir de informações obtidas em três sistemas: e-SUS Notifica, Sistema de Informação da Vigilância Epidemiológica da Gripe (Sivep-Gripe) e o Gerenciador de Ambiente Laboratorial (GAL).

Optou-se por ser usado mais de uma base de dados pois cada uma teve sua relevância para uma análise mais elaborada em informações nacionalmente abrangente e outra dados com foco no estado do Amazonas. Ambas as fontes possuem um volume significativo e relevante de dados. Para este trabalho, foram utilizados dados desde março de 2020, quando os primeiros casos de Covid-19 foram registrados, até dezembro de 2022.

A partir do dataset disponibilizado pelo Brasil IO foi utilizado os dados na tabela abaixo:

Nome da coluna/campo	Descrição	Tipo
date	Data das atualizações de casos registradas	data
state	Estado brasileiro registrado o dado	texto
situacao	Status do caso	texto
death	Informa se o paciente obteve cura ou veio a óbito	inteiro
is_last	Última atualização por estado	booleano

Já dos datasets disponibilizados pela Fundação de Vigilância em Saúde do Amazonas foi utilizado os dados abaixo:

Nome da coluna/campo	Descrição	Tipo
data	Data das atualizações de casos registradas	data
casos	Casos novos registrado naquele período de tempo	inteiro
etnias	Etnias dos povos indígenas	texto
município	Município onde caso foi registrado	texto
Faixa Etária	Faixa etária da população vacinada	inteiro
Dose1	Pessoas que tomaram a primeira dose da vacina	inteiro
Dose2	Pessoas que tomaram a segunda dose da vacina	inteiro
DoseUnica	Pessoas que tomaram vacina de dose única	inteiro

3. Processamento/Tratamento de Dados

Na análise exploratória, em primeiro momento foi verificado se existiam dados presentes de todos os estados, para que inicialmente fosse feito uma visualização da situação da pandemia de dimensão nacional. E foi constatado que a base possui informações de todos os 26 estados brasileiros e distrito federal, conforme verificação abaixo:

```
ultimas = estados.loc[estados.is_last==True, ['state','confirmed']]
len(ultimas)
```

✓ 0.0s

Os campos que originalmente continham valores nulos foram atualizados e atribuídos o valor 0 para fornecer uma abordagem mais adequada na análise. Essa alteração foi feita levando em consideração que a ausência de dados pode ser interpretada como a inexistência de mortes naquele dia específico, no estado ou cidade em questão. Dessa forma, essa abordagem busca fornecer uma representação coerente dos dados para uma análise mais precisa.

```
estados.isnull().sum()

estados.loc[estados.deaths.isnull(), 'deaths'] = 0
```

Foi utilizado coeficiente de Pearson para criar relação entre casos confirmados e mortes por Covid-19. Na estatística descritiva, o coeficiente de correlação produto-momento é utilizado para medir o grau e a direção da correlação entre duas variáveis de escala métrica, podendo ser intervalar ou de rácio/razão.



The screenshot shows a Jupyter Notebook interface with a play button icon and a timer. Below the code input area, a table displays the Pearson correlation matrix for the variables 'confirmed' and 'deaths'.

	confirmed	deaths
confirmed	1.000000	0.980338
deaths	0.980338	1.000000

Esse coeficiente, representado por ρ , varia apenas entre -1 e 1. A análise correlacional fornece informações sobre a relação entre duas variáveis lineares, com valores sempre situados entre +1 e -1. O sinal da correlação indica se ela é positiva ou negativa, enquanto o valor absoluto expressa a força dessa relação. É importante ressaltar que, como o coeficiente é calculado com base em um ajuste linear, a fórmula não incorpora informações sobre o ajuste em si, mas sim apenas os dados analisados.

Foi aplicada uma função logarítmica às colunas 'confirmed' e 'deaths' com o objetivo de obtermos uma visualização mais precisa. Ao apresentar os dados em uma escala logarítmica, é possível lidar de forma mais eficaz com uma ampla gama de valores, reduzindo-os para uma escala mais adequada e facilitando sua visualização.

```
ultimas['log_confirmed'] = np.log(ultimas['confirmed']+1)
ultimas['log_deaths'] = np.log(ultimas['deaths']+1)
```


A escala logarítmica comprime os valores maiores e expande os menores, o que ajuda a destacar detalhes importantes em uma faixa mais ampla de dados. Isso é especialmente relevante ao analisar gráficos e visualizações, pois permite uma melhor compreensão da magnitude das diferenças entre os valores.

Ao aplicar uma função logarítmica nas colunas 'confirmed' e 'deaths', buscou-se uma representação visual mais realista e informativa dos dados, para interpretar e comparar os números de maneira mais precisa.

4. Análise e Exploração dos Dados

Conforme detalhado no tópico anterior, será trabalhada duas bases de dados diferentes, onde a base disponibilizada pelo Brasil IO faremos análises utilizando Python e a biblioteca Pandas, NumPy e Folium.

Foram utilizadas funções do Pandas Series para plotagem de mapas, pois com ele é possível ler conjunto de dados que contém informações geográficas, identificadores de regiões. O Pandas pode ser usado para armazenar essas informações geográficas e, em seguida, ser usado como entrada para funções de plotagem de mapas oferecendo uma maneira eficiente de armazenar e manipular dados geográficos, além de permitir a integração com outras bibliotecas de plotagem geográfica populares.

```
import pandas as pd
import numpy as np
import folium
from folium import plugins
```

Folium é uma biblioteca Python de visualização de dados baseada em Leaflet.js, uma biblioteca JavaScript de mapeamento interativo. Ela permite criar mapas interativos e visualizações geoespaciais diretamente no seu ambiente de programação Python. Foram utilizadas as seguintes coordenadas para mapearmos o Brasil.

```
[ ] mapa = folium.Map(
    width=800, height=600,
    location=[-15.77972, -47.92972],
    zoom_start=4
)
```

Foi tratada a coluna place_type com a função loc, que serve para resgatar dados. Este método é primariamente baseado nas labels da colunas, porém podemos

utilizar com um array booleano também. Neste caso foi utilizado para pegar apenas os dados com o valor state.

```
estados = casos_covid.loc[casos_covid.place_type=='state',:]
estados.state.unique()

✓ 0.1s

array(['AP', 'AC', 'AM', 'AL', 'DF', 'ES', 'CE', 'BA', 'MS', 'MA', 'GO',
      'MT', 'PA', 'PE', 'PB', 'PI', 'RJ', 'MG', 'RN', 'RR', 'RO', 'PR',
      'SE', 'SC', 'TO', 'RS', 'SP'], dtype=object)
```

Foi comparado o número de mortes por Covid-19 com estados de população semelhante à do Amazonas. Os estados selecionados foram: Mato Grosso (MT), Rio Grande do Norte (RN), Paraná (PR) e Espírito Santo (ES).

```
casos_covid_estados = desde1caso(data,['AM','MT','RN','PR','ES'], 30,'deaths')
casos_covid_estados.plot()

✓ 0.0s
```

Foi comparado morte por Covid-19 por estados da região norte, que é composta pelo Amazonas e outros seis estados, sendo eles: Acre (AC), Amapá (AP), Pará (PA), Roraima (RR), Rondônia (RO) e Tocantins (TO)

```
mortes_covid_norte = desde1caso(data,['AC','AM','AP','PA','RR','RO','TO'], 30,'deaths')
mortes_covid_norte.plot()

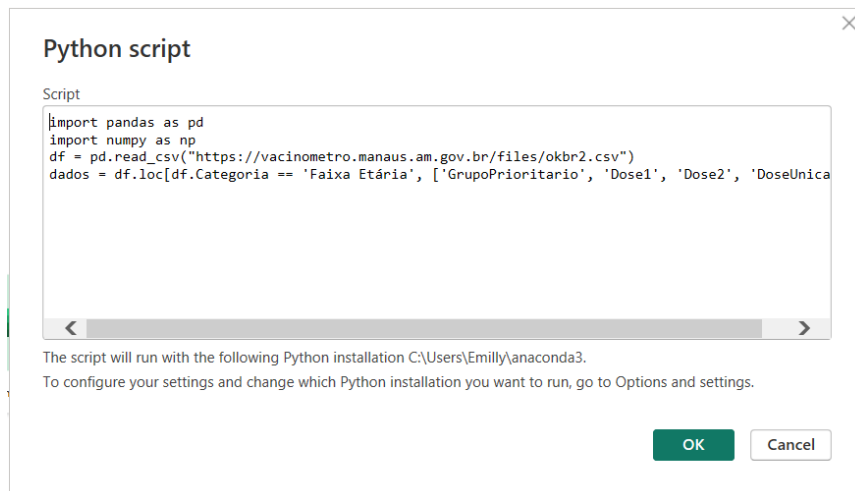
✓ 0.0s
```

Foi realizado a importação de um arquivo JSON contendo os dados das coordenadas geográficas dos estados. Para manipular esses dados, utilizou-se a função GeoJSON, que é um formato padrão aberto projetado para representar recursos geográficos e seus atributos não espaciais. Essa abordagem permitiu uma leitura eficiente e uma estruturação adequada dos dados geográficos, possibilitando uma análise geoespacial mais precisa e facilitando a visualização e manipulação dessas informações.

```
br_estados = 'br_states.json'
geo_json_data = json.load(open(br_estados))
```

Foi utilizado o Python Script Visual no Power BI para importar e manipular os dados do dataset da FSV (fonte de dados) e criar um novo visual baseado em Python.

No painel de propriedades do visual Python Script, escrevemos o código utilizando a biblioteca Pandas. O código foi projetado para realizar as manipulações e transformações necessárias nos dados, utilizando funções e recursos fornecidos pelo Pandas. Essas operações permitiram realizar as análises necessárias para a plotagem dos gráficos desejados no Power BI como pode ser observado na imagem abaixo.



Ao integrar as capacidades do Pandas ao Power BI, podemos explorar os dados de maneira simples e efetiva, realizando operações como filtragem, agregação, limpeza dos dados. Essas etapas preparatórias são essenciais para garantir a qualidade dos dados antes de sua utilização na criação de gráficos e visualizações.

Essas operações prévias ao processo de visualização permitem que os dados sejam preparados de forma adequada, garantindo a confiabilidade e a precisão das análises e gráficos gerados no Power BI. Ao combinar ao Pandas com as capacidades de visualização interativa do Power BI, podemos explorar os dados de maneira mais abrangente e identificar padrões e tendências.

5. Ferramentas e Modelos para Visualização de Dados

Conforme o documento de instruções para o TCC, essa etapa não é obrigatória, mas é fortemente recomendada. Caso você crie modelos de *Machine Learning* em seu projeto, nessa seção você irá descrever as ferramentas utilizadas. Se você utilizou ferramentas visuais como Knime e Rapid Miner, coloque aqui um print do seu modelo. Caso você tenha escrito scripts em Python, por exemplo, coloque aqui o seu script.

Explique as *features* utilizadas, justifique a escolha por determinado modelo, os parâmetros utilizados, etc.

Para aplicar as técnicas de visualização de dados foi escolhida a linguagem Python. As respectivas bibliotecas e ferramentas foram selecionadas a partir das utilizadas na disciplina de visualização de dados, linguagem de programação para ciência de dados e também em estudos pessoais.

Segue abaixo uma descrição de cada ferramenta e biblioteca do Python utilizada:

- **Pandas:** Biblioteca de software para manipulação e análise de dados. Em particular, oferece estruturas de dados e operações para manipular tabelas numéricas e séries temporais. Foi usada sobretudo para manipulação dos datasets apresentados.
- **Numpy:** Biblioteca fundamental para manipulação e análise de dados em Python e é amplamente utilizada em aplicações de computação científica, aprendizado de máquina e análise de dados.
- **Colab:** O Google Colaboratory é um ambiente de notebook interativo baseado em nuvem fornecido pelo Google. Ele permite escrever e executar código Python diretamente no seu navegador, sem a necessidade de configurar um ambiente de desenvolvimento local.
- **Power BI:** Ferramenta de inteligência de negócios e visualização de dados desenvolvida pela Microsoft. Ele permite que os usuários se conectem a várias fontes de dados, transformem e modelem dados e criem visualizações e relatórios interativos. O Power BI fornece um conjunto abrangente de recursos para análise de dados, exploração e compartilhamento de insights com outras pessoas.
- **Folium:** Biblioteca Python popular usada para criar mapas e visualizações interativas. Ele é construído sobre a biblioteca Leaflet.js e permite aos usuários gerar mapas com várias camadas, marcadores e outros elementos interativos.

Para a visualização dos dados obtidos, nosso objetivo principal do projeto, foram usadas três principais funções do pandas. Segue abaixo descrição dessas funções escolhidas e os parâmetros aplicados:

- **Concat:** A função `concat` é uma função do pacote pandas do Python utilizada para concatenar estruturas de dados, como `Series` ou `DataFrames`, verticalmente (ao longo das linhas) ou horizontalmente (ao longo das colunas). O `axis` é o eixo ao longo do qual a concatenação será realizada. Por padrão, é 0,

que indica a concatenação ao longo das linhas. Se axis for 1, a concatenação será realizada ao longo das colunas.

- Groupby: O groupby permite agrupar dados com base em uma ou mais colunas e realizar operações de agregação nos grupos resultantes. É útil para análise exploratória de dados, permitindo calcular estatísticas descritivas e aplicar transformações em subconjuntos de dados específicos.

```
estado = 'AM'
situacao = 'confirmed'
df_estado = data.loc[data.state==estado, :]
df_estado = df_estado.groupby('date').sum()[situacao].reset_index()
df_estado = df_estado.drop("date", axis=1)
df_estado.columns = [estado]
covid = pd.concat([covid, df_estado], ignore_index=True, axis=1)
```

- Foi utilizado o mapa.choropleth, que é uma função que permite a criação de mapas coropléticos no Python, utili-

```
[45] def desde1caso(data, estados, dias, situacao):

    covid = pd.DataFrame()

    for estado in estados:
        try:
            df_estado = data.loc[data.state==estado, :]
            df_estado = df_estado.groupby('date').sum()[situacao].reset_index()
            df_estado = df_estado.drop("date", axis=1)
            covid = pd.concat([covid, df_estado], ignore_index=True, axis=1)
        except:
            print("Is not " + situacao + " in " + estado )

    covid.columns = estados

    return covid.head(dias)
```

zando um DataFrame do pandas com informações geográficas e valores numéricos. Ele oferece flexibilidade na personalização dos mapas e pode ser combinado com outras bibliotecas de plotagem geográfica para obter resultados visuais impactantes e informativos.

6. Apresentação dos Resultados

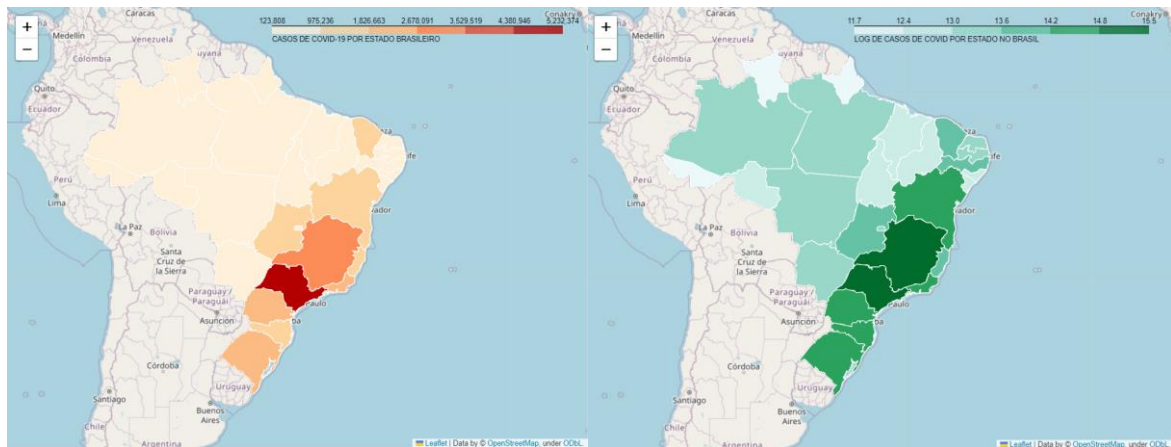
6.1 A realidade da Covid-19 no Brasil

Entre fevereiro de 2020,

```
mapa.choropleth(
    geo_data = geo_json_data,
    name = "CASOS",
    data = ultimas,
    columns = ['state', 'log_deaths'],
    key_on = 'feature.id',
    fill_color = "Reds",
    fill_opacity = 1.0,
    line_color = 'white',
    line_opacity = 1.0,
    show = True,
    legend_name = "MORTES POR COVID-19 POR ESTADO BRASILEIRO"
)
```

quando foi confirmado o primeiro caso de COVID-19, e dezembro de 2022, o Brasil já havia ultrapassado a marca de 35 milhões de casos confirmados, com mais de 700 mil mortes.

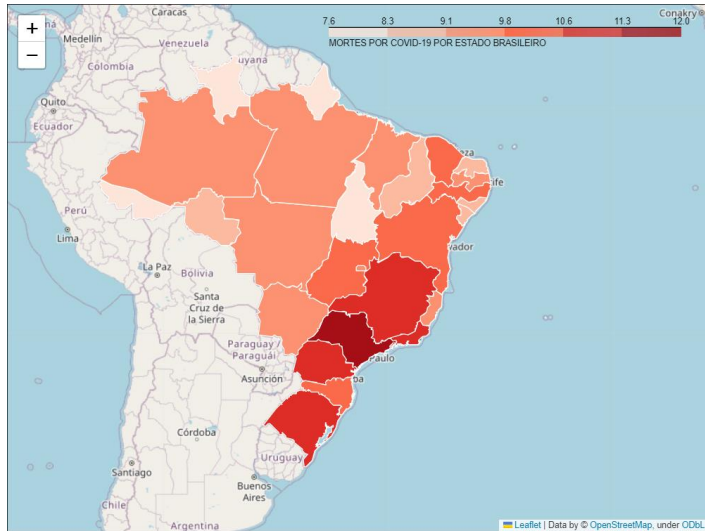
Ao analisarmos os dados nacionalmente, observa-se que os estados mais populosos também apresentam o maior número de casos confirmados. Foi plotado dois mapas epidemiológicos para visualizarmos o impacto de forma nacional, em número de casos confirmados. No gráfico a esquerda foi utilizado número absolutos de casos confirmados no de Covid-19, ou seja, na escala aritmética e no da direita foi utilizado o log.



No gráfico à esquerda, pode-se observar que a situação da Covid-19 parecia menos grave em grande parte do território nacional, principalmente nos estados com menor densidade populacional. No entanto, quando analisado o segundo gráfico, o qual optou-se por utilizar uma escala logarítmica, torna-se evidente que estados das regiões norte, nordeste e centro-oeste também foram significativamente afetados pela pandemia.

Ao utilizar o logaritmo das mortes confirmadas, foi possível suavizar as diferenças absolutas entre os estados e visualizar as proporções relativas de maneira mais equilibrada. Essa abordagem permite uma compreensão mais clara do impacto da Covid-19 em diferentes regiões.


O mapa epidemiológico abaixo foi gerado utilizando o logaritmo das mortes confirmadas por Covid-19. Ao analisar o mapa, podemos observar que os estados com maior densidade populacional apresentaram o maior número de óbitos relacionados à doença.



Essa visualização ressalta a correlação entre a densidade populacional e o impacto da Covid-19, evidenciando que regiões mais densamente povoadas enfrentaram uma maior incidência de mortes causadas pela doença. Essa tendência pode ser atribuída a uma série de fatores, como maior circulação de pessoas, maior dificuldade de implementar medidas de distanciamento social e maior demanda por serviços de saúde.

6.2 Comparando o Amazonas com outros estados


Quando se compara o Amazonas com os outros estados da região norte, podemos visualizar que o estado com o maior número de mortes da região norte foi o Amazonas.



Segundo uma análise feita por pesquisadores da Pontifícia Universidade Católica do Paraná (PUCPR) constatou que se levarmos em consideração o tamanho


populacional em números absolutos de afetados pela covid-19 terá uma ordem, entretanto se analisarmos a taxa de morte por 100 mil habitantes o estado do Amazonas liderou por semanas as taxas de mortes.

Comparando o estado do Amazonas com outros estados que possuem uma população semelhante, entre 3,2 e 3,5 milhões de habitantes, podemos observar uma diferença significativa no número de casos confirmados de Covid-19. Essa comparação é apresentada no gráfico abaixo, que inclui os estados do Mato Grosso, Rio Grande do Norte, Paraná e Espírito Santo.




Ao analisar o gráfico, fica evidente que o Amazonas se destaca em relação aos demais estados, apresentando um número muito maior de casos confirmados. Essa disparidade pode ser atribuída a uma série de fatores, como a densidade populacional em áreas urbanas, a infraestrutura de saúde disponível, a capacidade de realização de testes e o contexto socioeconômico.

Utilizando a relação entre os casos confirmados e as mortes por Covid-19, foi gerado o gráfico abaixo para destacar uma tendência importante: embora tenha havido um número expressivo de mortes, o número de pessoas curadas foi significativamente maior.



Ao observar o gráfico, podemos perceber que a quantidade de pessoas que se recuperaram da doença supera consideravelmente o número de óbitos registrados. Essa relação positiva entre os casos de recuperação e as mortes evidencia a resiliência e a capacidade de recuperação das pessoas afetadas pela Covid-19.

Ao analisar o gráfico abaixo, gerado utilizando recursos do Power BI, podemos observar que a região metropolitana de Manaus se destacou como a área com o maior número de casos confirmados e notificados de Covid-19. Em seguida, as regiões do Rio Negro e Baixo Amazonas também apresentaram uma significativa quantidade de casos.



Essa visualização ressalta a concentração dos casos na região metropolitana de Manaus, possivelmente devido à alta densidade populacional e à intensa atividade

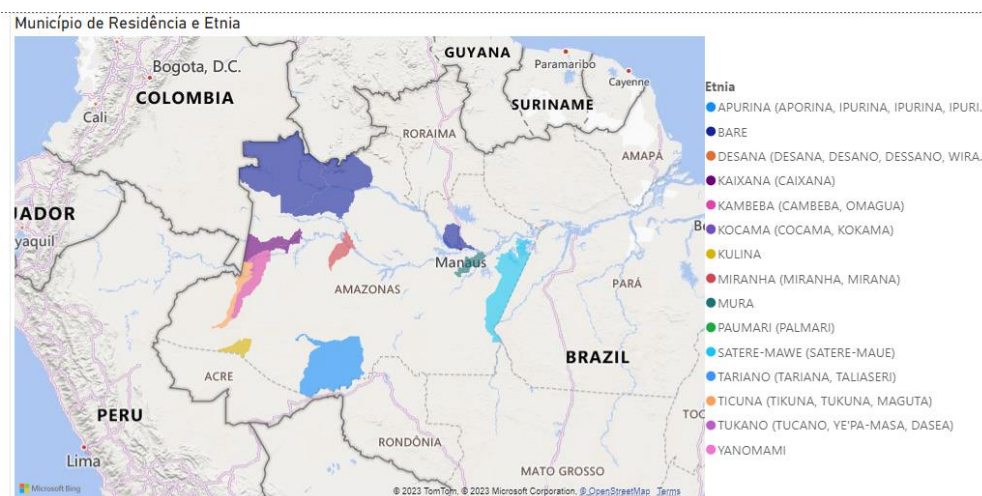
econômica da área. Esses fatores contribuíram para a propagação mais rápida do vírus.

6.3 Covid-19 para população indígena

O estado do Amazonas abriga a maior população indígena do país, sendo que na capital, de acordo com dados do IBGE, estima-se que haja aproximadamente 168.680 indígenas. No entanto, a subnotificação dos dados relacionados à COVID-19 teve impactos significativos na implementação do Plano de Enfrentamento da Covid-19 para os Povos Indígenas Brasileiros.

A pandemia da covid-19, doença causada pelo novo coronavírus (SARS-CoV-2), é uma grande ameaça à população indígena brasileira, principalmente aos povos e às comunidades de menor contato com a sociedade urbana, localizadas principalmente nas zonas rurais e regiões isoladas da Amazônia (Ferrante et al., 2020; Hallal et al., 2020; Rodrigues; Albertoni; Mendonça, 2020).

A situação foi agravada pelo fato de que muitos indígenas vivem em aldeias situadas em áreas geográficas de difícil acesso, onde os serviços de saúde e a infraestrutura são precários. Além disso, a distância entre essas comunidades e as unidades de saúde e hospitais de referência dificulta a remoção de pacientes graves. Esses desafios são ainda mais pronunciados entre os povos que possuem uma longa história de contato com a sociedade envolvente. Abaixo podemos observar os municípios Amazonenses onde vivem as tribos indígenas afetadas pela Covid-19.




Dessa forma, a subnotificação de casos e a dificuldade de acesso aos serviços de saúde teve um impacto negativo na resposta à pandemia entre os povos indígenas

De acordo com um estudo realizado pelo Instituto de Pesquisa Ambiental da Amazônia (IPAAM) e a Coiab, a mortalidade entre os indígenas era 150% mais alta do que a média nacional, e 20% mais alta do que a registrada na região Norte, a mais elevada entre as cinco regiões do país. A taxa de letalidade, que é número de óbitos pelo número de casos confirmados, também é maior que a média brasileira: entre os indígenas ela é de 6,8%, enquanto entre os não indígenas é 5,0% e na região Norte, 4,5%.

6.4 Vacinação tardia

A vacinação contra a COVID-19 no Amazonas teve início em 19 de janeiro de 2021, 9 meses após a confirmação do primeiro caso no estado. Nessa data, o estado começou a receber as primeiras doses das vacinas CoronaVac, desenvolvida pela Sinovac em parceria com o Instituto Butantan, e da vacina AstraZeneca, em parceria com a Universidade de Oxford, produzida pela Fundação Oswaldo Cruz (Fiocruz).

Durante a campanha de vacinação, foi utilizado diferentes vacinas aprovadas pela Agência Nacional de Vigilância Sanitária (Anvisa), como CoronaVac, AstraZeneca e Pfizer-BioNTech, dependendo da disponibilidade e das estratégias adotadas. Abaixo um gráfico onde pode ser observado a vacinação por faixa etária e quais doses da vacina foi aplicada.




Assim como em outros estados do Brasil, a vacinação no Amazonas seguiu um plano nacional de imunização, com diretrizes estabelecidas pelo Ministério da Saúde., onde foi definido a ordem de prioridade dos grupos a serem imunizados. Os primeiros

grupos a receberem as vacinas foram os profissionais de saúde da linha de frente, indígenas aldeados e idosos residentes em instituições de longa permanência.

6.5 Falta de cilindros de Oxigênio

A falta de oxigênio levou a situações críticas, com hospitais relatando escassez de cilindros e falta de suprimento adequado para atender às necessidades dos pacientes. Infelizmente, isso resultou em muitas mortes evitáveis e um cenário desesperador para pacientes, familiares e profissionais de saúde.

No gráfico abaixo podemos observar o pico de hospitalizações por Covid-19 em Janeiro de 2021



Durante janeiro de 2021, o estado do Amazonas se tornou o epicentro de uma grave crise na área da saúde, em meio à pandemia de coronavírus no Brasil. O sistema de saúde do estado colapsou, resultando na trágica asfixia de mais de 60 pessoas devido à escassez de oxigênio. A quantidade de mortos excedeu a capacidade dos cemitérios, levando ao uso de covas coletivas para os enterros.

7. Conclusão

O presente estudo teve como objetivo utilizar técnicas de visualização de dados para compreender a situação do Amazonas em relação à propagação e impacto da COVID-19 em comparação do Amazonas em relação aos demais estados da mesma região, bem como estados com população aproximada, durante um período de cerca

de três anos de pandemia, e através disso compreender quais fatores levaram o Amazonas a sofrer impactos significativos com a pandemia. Foram examinados dados, tanto a nível estadual quanto nacional, diversos indicadores foram considerados nesta análise, bem como o número de casos confirmados, óbitos, taxas de incidência e letalidade, entre outros.

A abordagem comparativa entre os estados do Amazonas e outros estados da mesma região, assim como estados com população aproximada, possibilitou identificar padrões e diferenças significativas na propagação e impacto da COVID-19. Essas análises comparativas foram fundamentais para embasar decisões e políticas de saúde pública, contribuindo para uma melhor compreensão dos fatores que influenciam a disseminação da doença em diferentes contextos.

O período de aproximadamente três anos foi escolhido para capturar tanto o início quanto o desenvolvimento da pandemia, permitindo uma compreensão mais completa das tendências e variações ao longo do tempo, para compreendermos os picos de casos confirmados, colapso do sistema de saúde amazonense e também a real situação da população indígena amazonense.

8. Links

Os scripts Python utilizados neste trabalho estão disponibilizados no repositório: www.github.com/emillyvale/PUC-TCC-emillymagalhaes. Este scripts foram criados na ferramenta Google Colab. Os demais links abaixo foram fontes de pesquisar e busca de dados para análise.

https://www.fvs.am.gov.br/media/uploads/sala_de_situacao/COVID_AMAZO-NAS2023_HLSpju8.csv

https://www.fvs.am.gov.br/media/uploads/sala_de_situacao/COVID_AMAZO-NAS2022_kR3fea6.csv

https://www.fvs.am.gov.br/media/uploads/sala_de_situacao/COVID_AMAZO-NAS2021_8FCDAkw.csv

https://www.fvs.am.gov.br/media/uploads/sala_de_situacao/COVID_AMAZO-NAS2020_SI3cx0Z.csv

<https://brasil.io/dataset/covid19/caso/>

https://www.fvs.am.gov.br/indicadorSalaSituacao_view/75/2

<https://vacinometro.manaus.am.gov.br/files/okbr2.csv>

REFERÊNCIAS

HALLAL, P. C. et al. SARS-CoV-2 antibody prevalence in Brazil: results from two successive nationwide serological household surveys. *The Lancet Global Health*. v. 8, n. 11, p. 1390-1398, 2020.

BRASIL. Ministério da Saúde. Fundação Nacional de Saúde (FUNASA). Política Nacional de Atenção à Saúde dos Povos Indígenas. Brasília, DF: FUNASA: 2002.

MATTA, Gustavo Corrêa. Os impactos sociais da Covid-19 no Brasil. Rio de Janeiro, 2022.